Casamento de cadeias

Universidade Estadual de Mato Grosso do Sul
Bacharelado em Ciência da Computação
Algoritmos e Estruturas de Dados II
Prof. Fabrício Sérgio de Paula

Tópicos

- Introdução
- Problema do casamento de cadeias
- Algoritmo da força bruta
- Algoritmo de Knuth, Morris e Pratt
- Exercícios

Introdução

- Cadeia: sequência de elementos chamados caracteres
  - Caracteres pretencem a um alfabeto
    - Ex.: 0110010 é uma cadeia do alfabeto {0, 1}
  - Comprimento de uma cadeia: quantidade de caracteres
    - Ex.: 0110010 é uma cadeia de comprimento 7
  - Aplicações de cadeias de caracteres: processamento de textos, dicionários, codificação de dados, sequenciamento de DNA, criptografia, etc.

Problema do casamento de cadeias

- Sejam X e Y duas cadeias de comprimentos n e m, respectivamente, onde $n \geq m$
  - X e Y estão armazenadas em vetores, onde x_i e y_i são tais que $1 \leq i \leq n$ e $1 \leq j \leq m$
  - Y é subcadeia de X se Y é subsequência de elementos consecutivos de X
    - Nesse caso existe $l \leq n - m$ tal que $x_{l+j} = y_j$ para todo $1 \leq j \leq m$
    - Se $l = 0$, Y é um prefixo (próprio, se $m \neq n$) de X
    - Se $l = n - m$, Y é um sufixo (próprio, se $m \neq n$) de X
  - X_k: subcadeia de X iniciando no índice k

Problema do casamento de cadeias

- Problema do casamento de cadeias: Y é subcadeia de X?
  - Caso seja, localizar Y em X: encontrar índice l
    - Nesse caso, houve um casamento de Y com X na posição l+1
  - Ex. 1: X = baaabea e Y = aabe
    - Y é subcadeia de X
    - l = 2
    - Houve casamento de Y com X na posição 3
  - Ex. 2: X = baaabea e Y = aeb
    - Y não é subcadeia de X

Problema do casamento de cadeias

- Exemplo:

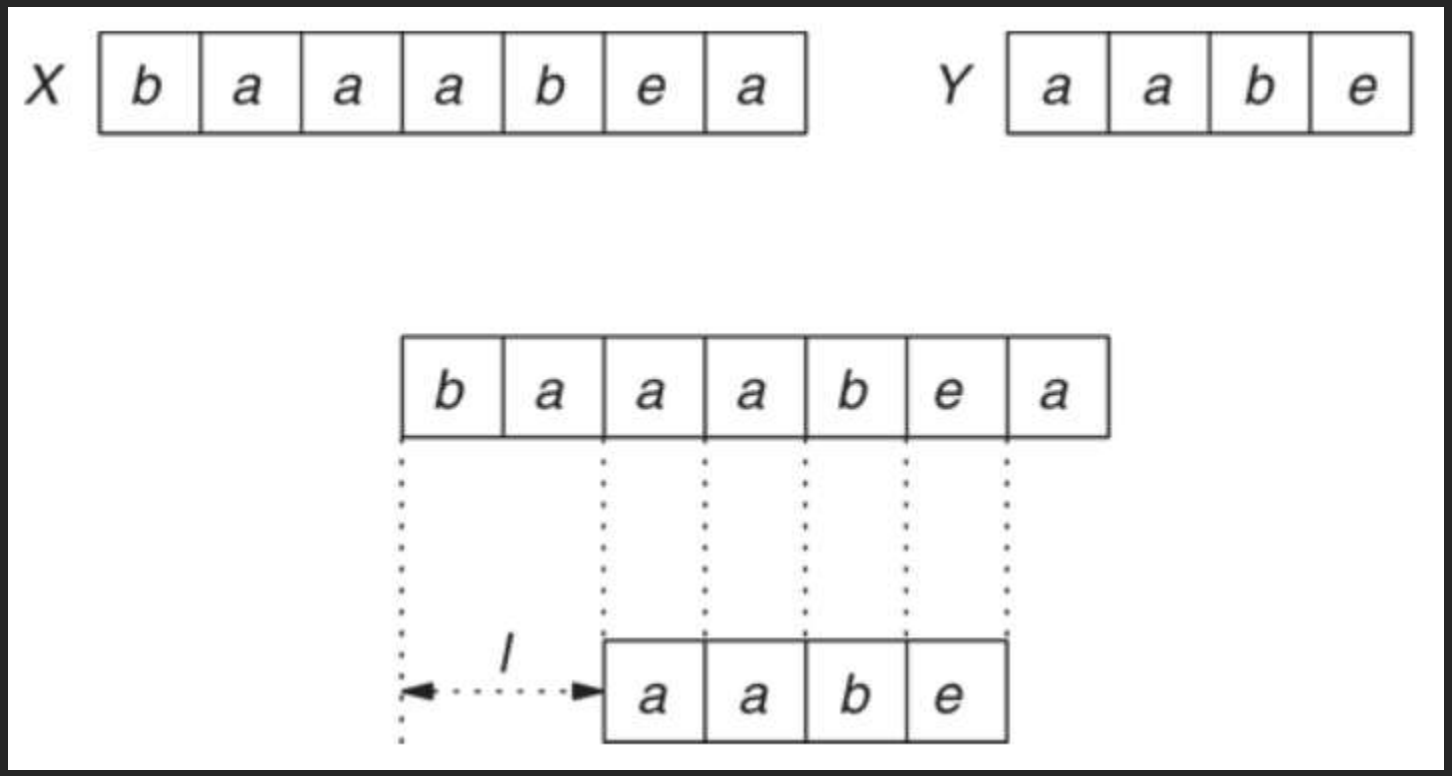

Algoritmo da força bruta

- Algoritmo da força bruta: verifica se Y é subcadeia de X testando todas os possíveis valores para l
  - Para l = 0, 1, ..., n – m, verificar se todos os caracteres de Y são encontrados em X
  - Caso Y seja encontrado em X, o algoritmo termina e o valor atual de l+1 é retornado

Algoritmo da força bruta

- Algoritmo:

```
algoritmo 10.1: Casamento de cadeias
    para ℓ := 0, ..., n − m faça
        i := 1
        teste := V
        enquanto i ≤ m e teste faça
            se x[ℓ + i] = y[i] então
                i := i + 1
            senão teste := F
        se teste então
            "casamento na posição ℓ + 1"
            pare
    "não há casamento"
```

Algoritmo da força bruta

- Exemplo:

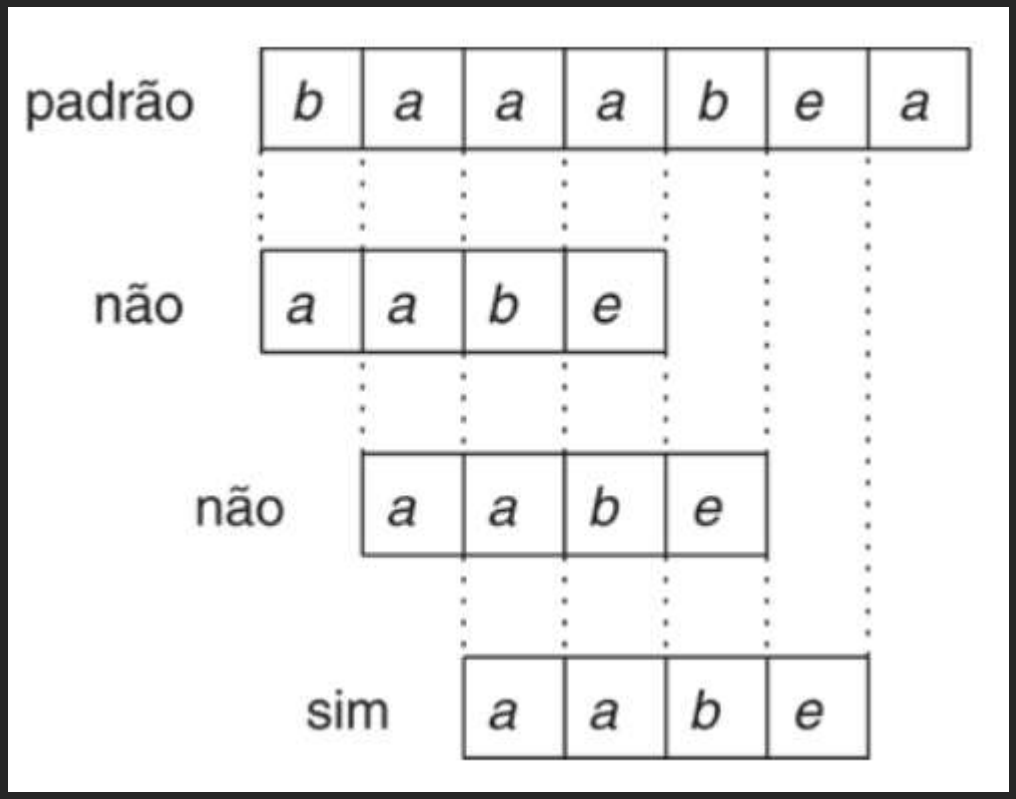

Algoritmo da força bruta

- Complexidade de tempo:
  - Pior caso: O(m n)
    - Para todos os valores de l, comparações são efetuadas até o último caracter de X, que será diferente
      - n – m + 1 tentativas com m comparações cada
  - Melhor caso?

Algoritmo de Knuth, Morris e Pratt

- Comparações do algoritmo da força bruta:

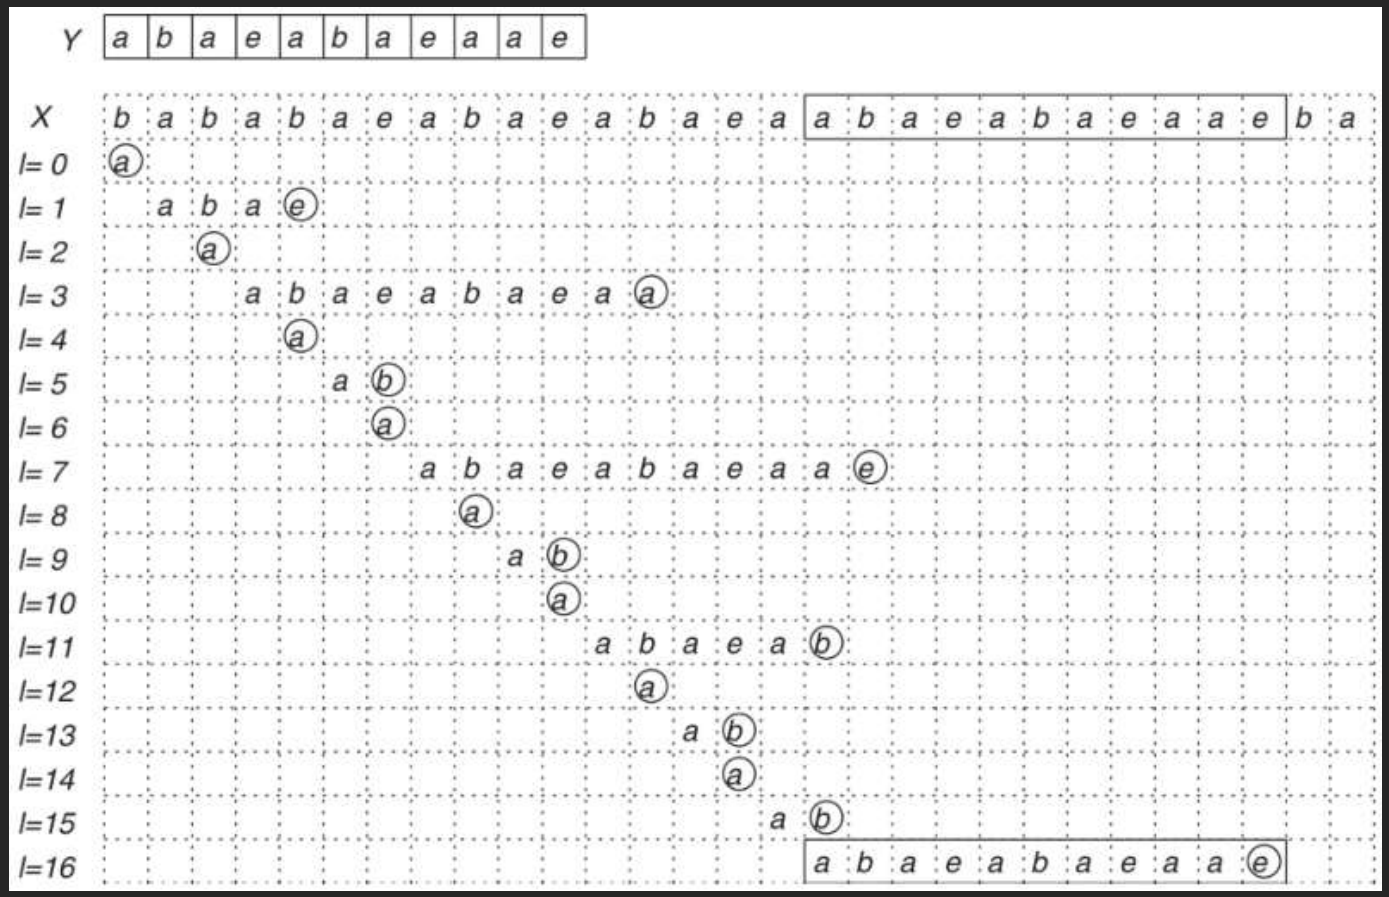

Algoritmo de Knuth, Morris e Pratt

- Algoritmo de Knuth, Morris e Pratt (KMP): considera fato de que nem todas comparações do algoritmo da força bruta são necessárias
  - Realiza análise dos prefixos de Y: permite descartar comparações que, com certeza, não levariam ao casamento
    - No exemplo, subcadeias X_3 (l=2), X_5 (l=4), X_6 (l=5), X_7 (l=6) e outras

Algoritmo de Knuth, Morris e Pratt

- Suponha exame da subcadeia X_{l+1} com discordância no índice $k > 1$:
  - $x_{l+i} = y_i$, $1 \leq i < k$ e $x_{l+k} \neq y_k$
  - X_{l+2} deve ser examinada?
    - Os k-1 caracteres iniciais de X_{l+1} formam prefixo de Y e k-2 também fazem parte de X_{l+2}
    - Se $X_{l+2} = Y$, então, em particular, os k-2 caracteres iniciais devem coincidir, ou seja, $x_{l+1+i} = y_i$
      - É possível saber se isso ocorre sem analisar X_{l+2}: basta analisar se $y_i = y_{i+1}$, $1 \leq i < k-1$. Ou seja, deve-se analisar se o prefixo $y_1,\ldots,y_{k-2}$ coincide com o sufixo $y_2,\ldots y_{k-1}$, ambos de $y_1,\ldots,y_{k-1}$ e tamanho k-2
      - Esse fato independe da cadeia X

Algoritmo de Knuth, Morris e Pratt

- Generalizando, se, ao examinar X_{l+1}, y_k difere:
  - Então, uma subcadeia X_{l+1+h}, $h < k-1$ pode casar com Y somente se $y_i = y_{i+h}$, $1 \leq i < k - h$: só nesse caso é examinada
  - A próxima subcadeia a ser examinada é X_{l+1+h}, onde h é o menor valor onde $y_i = y_{i+h}$, $1 \leq i < k - h$
  - O valor de h não depende de X: só de Y e k
  - O algoritmo KMP calcula h de forma indireta: é calculado d(k-1), que é o comprimento do maior prefixo de $y_1,\ldots,y_{k-1}$ que coincide com o sufixo de mesmo tamanho de $y_1,\ldots,y_{k-1}$
    - Se nenhum prefixo-sufixo coincide, então d(k-1) = 0
    - O valor mínimo de h é, então, h = k-1 - d(k-1)

Algoritmo de Knuth, Morris e Pratt

- Outras comparações também podem ser descartadas: nem sempre é necessário examinar todos caracteres da subcadeia X_{l+1+h} após X_{l+1}
  - Como $x_{l+i} = y_i$, $1 \leq i < k$ e $y_i = y_{i+h}$, $1 \leq i < k-h$, então os d(k-1) caracteres iniciais de X_{l+1+h} coincidem com $y_1,\ldots,y_{d(k-1)}$
    - Nesse caso, a próxima comparação será entre x_{l+k} e $y_{d(k-1)+1}$
  - Se k = 1, a subcadeia X_{l+1} e Y diferem no primeiro caracter, então X_{l+2} deve ser examinada
    - Nesse caso, a próxima comparação será entre x_{l+2} e y_1
  - Em ambos os casos, o índice de X não retrocede
    - Algoritmo nunca retrocede índice de X

Algoritmo de Knuth, Morris e Pratt

- Exemplo do cálculo de d(9):
  - d(9) é o tamanho do maior prefixo que coincide com o sufixo de $y_1,\ldots,y_9$:
    - d(9) = 5, do casamento do prefixo com o sufixo abaea

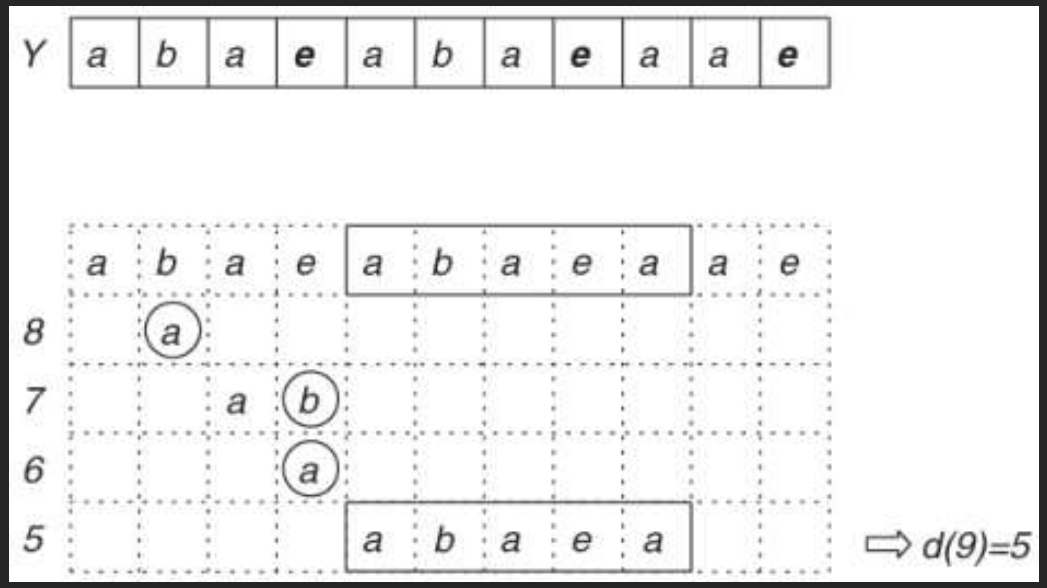

Algoritmo de Knuth, Morris e Pratt

- Exemplo: após analisar a subcadeia $X_4 = X_{l+1}$ ($l = 3$), há discordância no índice $k = 10$, pois $x_{3+10} = b \neq a = y_{10}$
  - Próxima cadeia a ser analisada é $X_{l+1+h} = X_{4+h}$
  - $h = k-1 – d(k-1) = 9 – d(9) = 9 – 5 = 4$
  - Logo, próxima cadeia a ser analisada é $X_{4+4} = X_8$
    - São descartadas as subcadeias X_5, X_6 e X_7
  - Além disso, ao analisar X_8 não é necessário comparar $y_1,\ldots,y_{d(k-1)} = y_5$ com $x_8,\ldots,x_{12}$, pois sabe-se que são coincidentes
    - A próxima comparação será entre y_6 e x_{13}

Algoritmo de Knuth, Morris e Pratt

- Algoritmo KMP:

```
algoritmo 10.2: Casamento de cadeias
i := j := 0
enquanto i − j ≤ n − m faça
        teste := V
        enquanto j < m e teste faça
                se X[i + 1] = Y[j + 1] então
                        i := i + 1
                        j := j + 1
                senão teste := F
        se teste então
                "casamento na posição i − m + 1"
                pare
        se j = 0 então i := i + 1
        senão j := d[j]
"não há casamento"
```

Algoritmo de Knuth, Morris e Pratt

- Algoritmo para cálculo dos valores de d:

```
algoritmo 10.3: Determinação do vetor d
j := d[1] := 0
k := 1
enquanto k < m faça
        se Y[k + 1] = Y[j + 1] então
                k := k + 1
                j := j + 1
                d[k] := j
        senão se j = 0 então
                        k := k + 1
                        d[k] := 0
                senão j := d[j]
```

Algoritmo de Knuth, Morris e Pratt

- Cálculo dos valores de d:

Y	a	b	a	e	a	b	a	e	a	a	e	
k	a	b	a	e	a	b	a	e	a	a	e	
2		(a)										⇨ d(2)=0
3			a									⇨ d(3)=1
4				(b)								
4				(a)								⇨ d(4)=0
5					a							⇨ d(5)=1
6						b						⇨ d(6)=2
7							a					⇨ d(7)=3
8								e				⇨ d(8)=4
9									a			⇨ d(9)=5
10										(b)		
10										(b)		
10										a		⇨ d(10)=1
11											(b)	
11											(a)	⇨ d(11)=0

Algoritmo de Knuth, Morris e Pratt

- Comparações do algoritmo KMP:

Y	a	b	a	e	a	b	a	e	a	a	e

X	b	a	b	a	b	a	e	a	b	a	e	a	b	a	e	a	a	b	a	e	a	b	a	e	a	a	e	b	a
l= 0	a																													
l= 1		a	b	a	e																									
l= 3					b	a	e	a	b	a	e	a	a																	
l= 7													b	a	e	a	a	e												
l=16																		b	a	e	a	b	a	e	a	a	e			

- Complexidade: O(n+m)
  - Índice de X não retrocede
  - Índice de Y nem sempre volta ao início

Exercícios

- 10.1, 10.2, 10.4 e 10.13